潘志超 ZhiChao Pan

AI Agent 高频用户 / 模型回复评测与任务拆解

计算机科学与技术专业学生，长期使用 AI Agent 完成研究、代码、数据处理、内容生成与自动化任务。 熟悉多轮 prompt 调整、rubric 拆解、模型回复对比和失败模式分析，能把“模型回答得好不好”转化为清晰、可复查的评分依据。

Email 18652585856@163.com
Website www.panzhichao.com
GitHub github.com/Zhi-Chao-PAN
Location 江苏扬州 / 可远程协作

与本次 AI AGENT 评测任务的匹配点

高频真实使用
日常累计使用 Agent 约 6-8 小时，复杂任务常持续 1-2 小时以上。

会写 Rubric
能拆出事实准确性、任务完成度、约束遵守、可执行性、表达质量。

能做模型对比
熟悉多模型回复对比、追问修正、失败模式定位和输出重写。

熟悉复杂场景
覆盖代码、RAG、长文档、数据分析、办公自动化和内容生成任务。

核心能力

- Prompt 设计：任务拆解、上下文组织、约束设定、输出格式控制。
- Agent 评测：rubric 编写、逐项评分、模型回复对比、错误归因。
- 代码任务：TypeScript / Next.js / React / Python，能调试、重构和写脚本。
- 数据与文档：RAG、表格/文档解析、实验记录、结构化报告生成。
- 内容与办公：检索总结、文档改写、技术说明、产品方案和流程设计。

教育背景

扬州大学广陵学院 **本科在读**
计算机科学与技术专业
正在准备海外高校 AI / 计算机相关硕士方向；长期方向是应用 AI 产品工程与全栈智能体架构。

代表项目经历

Codex ↔ ZCode Remote Relay - 多智能体任务调度与验收工作流 **Node.js / JSON-RPC / WebSocket**

- 设计 Codex 指挥、ZCode 执行的本地多 Agent 协作协议，包含任务边界、文件所有权、模型选择、状态回收和验收门禁。
- 建立 jobId / taskId / worker ledger 机制，记录目标、修改范围、验证命令、风险和最终采纳状态，直接对应 Agent 任务评测中的过程审计。

Model Eval Studio - 多模型评测工作台 **Next.js / React / TypeScript**

- 围绕模型选择设计评测界面：识别截图或产物来源，抽取延迟、成本、输出质量等信号，并生成结构化比较报告。
- 强调可审计的评测结论，而不是只看排行榜或单次输出，适合模型回复对比和质量判断任务。

LaunchLens AI / Research Studio - 多 Agent 产品研究系统 **Next.js / Zod / Multi-Agent**

- 将市场、竞品、用户、定价、渠道、风险拆成多个专业 Agent 并行研究，再合并成可复用的 GTM brief。
- 使用结构化输出和校验思路组织模型结果，关注“回答能否被复核、修正、复用”。

Structure-Aware RAG Empirical - 文档解析与 RAG 评测实验 **Python / LlamaIndex / LlamaParse**

- 设计 parser-controlled benchmark，对比结构感知解析与普通 PDF 解析对金融文档 RAG 准确率的影响。
- 在固定模型和问题条件下报告约 37.5% 的相对准确率提升，强调可复现、可解释的评测流程。

LangGraph Financial Swarm - 金融研究多 Agent 系统 **Python / LangGraph / Local LLM**

- 设计宏观、行业、公司、情绪、风险等 specialist agents，通过状态机协作生成可追踪研究报告。
- 关注角色分工、共享状态、checkpoint 和最终审阅步骤，适合评估复杂多步 Agent 回复的逻辑一致性。

Safety-Critical Battery Prognostics - 可靠机器学习与不确定性评估 **Python / PyTorch / Conformal Prediction**

- 构建电池剩余寿命预测实验，结合物理约束、ISO-26262 安全边界和 conformal prediction。
- 强调模型结论必须带有边界、置信度和可复现实验记录，训练了对“看似正确但过度自信”输出的敏感度。

实际评测方法

先拆任务
把目标、输入限制、输出格式、关键事实、不可接受错误先列清，再看模型是否真正完成任务。

再看证据
对涉及事实、代码、数据和长文档的回答，优先检查引用依据、步骤可执行性和遗漏风险。

最后给建议
输出评分、扣分点、可改写 prompt、下一轮追问方向和更稳妥的回复版本。

技术栈

AI Agent Workflow · Prompt / Rubric · Model Evaluation · RAG · LangGraph · LlamaIndex · TypeScript · Next.js · React · Python · Node.js · Data Processing

可承担的评测任务类型

- 对 prompt 进行 rubric 编写、评分维度拆解和改写建议。
- 对多个模型回复做事实性、完整性、可执行性、表达质量对比。
- 处理代码调试、数据分析、办公文档、内容生成、自动化流程类任务。
- 输出清晰评测记录：结论、证据、扣分点、改进建议和风险提示。

更多项目细节和在线链接：panzhichao.com/projects/codex-zcode-remote-relay · panzhichao.com/projects/model-eval-studio · panzhichao.com/projects/structure-aware-rag-empirical