

研究项目作品集

AutoResearch 二期申请 | 论文方法 · 可运行任务 · 负结果与可复核证据

潘志超 · 扬州大学广陵学院 · 计算机科学与技术 · 本科三年级

在读 2024.09—2028.06（预计）。申请按公开成果酌情考虑；三个项目均有固定审阅入口和可核查的结果。

6 次

研究代理的开发集反馈预算

21 条

LoRA 固定快照训练记录

17 项

Playbook v0.2.0 测试

为什么这三项与招募要求相符

读论文并判断任务适配：RRF/BEIR 的公开方法被映射为一个只编辑权重与 k 的 CPU 检索任务。加权参数搜索是本项目扩展，不能当作原论文复现。

运行代码并处理环境问题：研究代理项目固定评分器和离线检查；LoRA 项目记录 BPE merges 输入错误、撤回旧解释和纠错重训，均有版本与核验入口。

研究判断：研究代理结果没有胜过预设搜索；LoRA 的 PAWS 结果接近常量分类基线。两项都保留不利结果及实验边界。

评测工程：Playbook 把任务包、规则文本和数值容差做成可执行检查入口。

四步核验路线 | 评审无需先读完整仓库

01 看问题：[项目证据页](#) 展示实验目标、流程和链接。

02 看任务：[Research Agent 固定 r2](#) → [英文论文到任务对照](#) → 评价器与六轮轨迹。

03 看失败：[LoRA 固定 Release](#) → 输入纠错、MRPC 与 PAWS 分歧。

04 看工程：[Playbook v0.2.0](#) → 三个工具、17 项测试与多版本 CI。

审阅提示：固定 Release 中保留协议、结果与限制；建议重点检查方法取舍、输入纠错和为什么没有胜过基线。

01 Research Agent Bench

把 RRF / BEIR 方法转成可限制反馈预算的研究代理任务

论文方法 → 本项目任务：明确继承与改动

[RRF 原文](#) 研究排序融合，试验中固定 $k=60$ 。本项目用 BM25 与 TF-IDF 两路排名，改为 $w/(k+rBM25) + (1-w)/(k+rTFIDF)$ ，限定 $k \in [1,200]$ 、 $w \in [0,1]$ 。

[BEIR 论文](#) 提供检索基准与稳健比较背景；这里仅使用 NFCorpus 一个数据集，不支持跨数据集泛化主张。

判断适合转任务的理由：可固定输入和指标；候选只含两个数；CPU 反馈快；非法参数可拒绝；同预算搜索提供必要参照。

任务闭环



结果解释 | 可运行，但未展示优化优势

三条新增六轮 LLM 轨迹均选择 $k=100$ 、BM25 权重 0.5，形成一组唯一公开测试排序；不能按三份独立泛化结果计数。主指标为指数增益 nDCG@10，不与线性增益榜单直接混用。

189 点参数面与 100 组各六次的随机搜索是事后数值对照；100 组不是 100 次 LLM 代理运行。公开测试包含 323 条查询，且参数面此前被查看，不能称盲测。

发布后在同机新 Python 环境重新获取 BEIR 固定快照、重建缓存并复核归档数值。本机下载日志不是独立来源证明；指标检查器仍共享排名缓存和公开标签，不能当作跨机复现或盲测。

点击核对原始证据

[r2 固定 Release](#) · [PAPER TO TASK 对照](#) · [BEIR 同机新获取复跑](#)

建议评审优先查看协议中的预算/评分规则，再查看公开轨迹和负结果。固定标签的归档结果与发布后复跑分开保存。

02 LoRA 输入纠错与负结果

MRPC 常规句对表现不能直接外推为 PAWS 词序鲁棒性

研究设计与首先必须修正的输入

比较分类头、全量微调与 query/value LoRA-r8；每种方法在 4/12 轮、三个种子下运行，共 18 次主训练。另有两次单种子 rank 诊断及一次从头重复，固定快照共 21 条记录。

旧 tokenizer 未加载 BPE merges。项目撤回旧性能解释，对 4,076 条 MRPC 编码审计，再按纠正后的输入重训；这一点比沿用错误结果更能展示故障定位与研究自纠。

方法对应英文笔记、固定代码与结果清单；本项目是受原方法启发的实验比较，不把特定数值宣称为原论文原样复现。

12 轮固定选择后的关键结果

方法	MRPC 平均 F1	PAWS 平衡准确率	可支持的结论
LoRA-r8	0.9074	0.5009	MRPC 较好；PAWS 接近基线
全量微调	0.9081	0.5003	不能据此证明方法等效

如何解释失败，而非包装成功

两种方法的 PAWS balanced accuracy 均约 0.50，接近常量预测基线；MRPC F1 高不等于词序变化下稳定，也不能主张 LoRA 优于全量微调。

发布后从新空资产目录执行固定获取脚本，随后同机同软件环境复跑 LoRA-r8、seed 42、4 轮一个配置。公开日志及字段校验支持这一次同环境重复；本地下载日志不是独立网络证明。

公开 CI 只离线审阅记录，不重新下载或训练；该补充不覆盖全部 21 条归档训练或跨机复现。

点击核对原始证据

[固定 Release 与纠错说明](#) · [英文方法笔记](#) · [单配置上游复跑报告](#)

建议先查输入纠错记录，再核对 MRPC/PAWS 指标与 PAWS 基线，最后看复跑报告的同机限制。

03 评测工程与核验路线

项目证据可逐级核对，研究问题可通过现场交流追问

LLM Evaluation Playbook | 让评测规则可执行

task 包检查：确认必要文件、引用和表格结构；受测者材料与评审者材料隔离。

rubric 检查：促使评分点可观察、可判定，并提醒模糊或混合多个要求的条目。

数值容差检查：显式处理绝对、相对、百分点、区间和集合等规则；工具执行既定容差，不代替研究者决定容差是否合理。

固定 [v0.2.0 Release](#) 含三个标准库 Python 工具、17 项测试；CI 覆盖 Python 3.9 / 3.11 / 3.12。公开样例为合成材料，不包括 Xpert 私有任务。

证据层级 | 评审可据此决定追问什么

固定 Release：可检查当时公开的代码、协议、结果与限制。项目名和记录数量不等于科研能力认证。

发布后复跑：研究代理为同机新环境、共享重建缓存；LoRA 为同机单配置。两者的范围均写在对应报告中。

CI：证明指定测试与离线核验按记录运行。研究代理的 CI 不重建 NFCorpus；LoRA CI 不重新训练。

本人操作：9 月 23 日亲自完成六轮合成开发任务调用与先行假设，6/6 成功，选第 5 轮；私有日志含状态哈希。六题初稿有部分计时前预写，不声称全部限时撰写。

现场追问：可围绕英文方法、评价器入口、固定数据来源、命令运行和错误分析展开代码走查或限时试做。

岗位匹配与申请理由

本材料以三项公开项目对应岗位要求：研究方法转任务、模型输入纠错、评测检查工具。技术细节与复核范围可从固定 Release 和报告追溯。

目前为本科三年级，希望按公开成果酌情考虑；愿通过现场代码定位、命令运行和研究问题判断展示个人能力。

项目使用 AI 工具协作；本作品集陈述项目层面的公开成果，具体个人贡献可结合公开记录与现场交流核对。

统一入口

[项目证据页](#) · [GitHub 主页](#) · [研究代理 Release](#) · [LoRA Release](#) · [Playbook Release](#)