

01 Research Agent Bench

RRF / BEIR 方法 → 开发反馈预算 → 可检查的最终选择

研究项目作品集 | 三项研究 + 评测工程

围绕论文方法到可运行任务，整理检索研究代理、LoRA 输入纠错与电池容量重建三项研究；LLM Evaluation Playbook 补充评测工程。各案例保留实验设计、结果解释与固定复核入口。

方法来源与任务适配

[RRF 原论文](#)以倒数排名融合多个排序；本项目采用 $w/(k+rBM25)+(1-w)/(k+rTFIDF)$ ，把两个数作为候选。[BEIR 论文](#)提供异质检索评测背景，本项目仅使用 NFCorpus。

固定输入后反馈确定、CPU 求值快，适合反复尝试；参数低维也使预设搜索成为必要且有竞争力的基线。加权搜索是本项目扩展，不等于原论文实验的原样复现。

任务环节	实际约束或产物
输入与可修改项	冻结 BM25/TF-IDF 排名与标签；候选仅改整数 $k \in [1,200]$ 和有限权重 $w \in [0,1]$
反馈与预算	最多六次开发调用；调用前记录假设；拒绝重复候选及第七次调用
评价与选择	指数增益 nDCG@10；先按开发指标选择，再核对公开测试
交付与边界	任务说明、输入哈希、反馈、轨迹与冻结选择；流程约束不等于操作系统沙箱

结果与能支持的结论

代理 **0.307044**；预设六点搜索 **0.307294**。三条新增六次调用轨迹均选择 $k=100$ 、 $w=0.5$ ，产生一组唯一测试排序；重复选中支持有限的选择可重复性，不能算三份独立泛化结果。

189 点参数面与 100 组等预算随机搜索为事后数值对照。公开测试有 323 条查询，参数面此前被查看；本结果是探索性负结果，尚未证明代理胜过搜索。

复核与接手入口

发布后同机新环境获取固定 BEIR 快照、重建排名缓存并核对归档数值。检查器共享缓存和公开标签；本地获取日志支持执行记录，不提供独立网络来源认证。

[r2 固定 Release](#) · [论文到任务索引](#) · [数据重建报告](#)

02 LoRA 输入纠错与压力测试

先确认模型收到什么输入，再解释分数与方法差异

方法与实验设计

[LoRA 原论文](#)提出冻结预训练权重并训练低秩更新。本项目比较分类头、全量微调与 query/value LoRA-r8；采用 4/12 轮、三个种子，共 18 次主训练，另有两次 rank 诊断和一次重复。

MRPC 用于常规句对比较；在固定 12 轮 checkpoint 后查看 PAWS 词序压力表现。公开 validation/test 的使用属于探索性分析。

输入故障与修复

旧 tokenizer 路径缺少 BPE merges。项目撤回旧性能解释，审计 4,076 条 MRPC 编码，再按纠正后的输入重训；将纠错记录与旧结论保留供核查。

这个案例的价值在于定位输入路径错误并重新建立比较基础，而不是沿用错误输入产生的分数。

12 轮方法	MRPC 平均 F1	PAWS 平衡准确率
LoRA-r8	0.9074	0.5009
全量微调	0.9081	0.5003

结果解释与下一步判断

两种方法在 PAWS 的平衡准确率都接近常量分类基线。MRPC F1 较高，不能据此判断词序鲁棒；当前差值也不足以证明统计等效或 LoRA 优于全量微调。

后续若研究迁移，应预先固定模型选择与新评测协议，重点检查输入差异、负类召回和典型错误；这些是后续研究方向，不计入已完成成果。

复核与接手入口

固定快照含 21 条训练记录；发布后同机、同软件环境追加 LoRA-r8/seed 42/4 轮一个配置的复跑。公开 CI 审阅归档记录，单配置复跑不覆盖全部矩阵。

[固定 Release 与纠错记录](#) · [英文方法笔记](#) · [单配置复跑](#)

03 电池容量重建与机制审查

六电芯留一验证 · 三训练种子 · 公平后处理对照

问题、数据与协议

研究物理约束模型在电池容量重建中是否带来更好的准确性和训练稳定性。使用仓库 CS2_33—CS2_38 六个快照，每折以五个电芯训练、留出一个电芯评价。

训练种子为 42/123/456；固定噪声设置；PINN 与 LSTM 统一使用 EMA ($\alpha=0.15$) 及 running-min。每个模型 18 个种子×电芯组合，共 36 条模型/折汇总。

训练种子	PINN 平均 RMSE / Ah	LSTM 平均 RMSE / Ah
42	0.3124	0.2216
123	2.3953	0.2224
456	0.2365	0.2222

每项为六个留出电芯的均值。18 个种子×电芯组合整体均值：**PINN 0.9814 Ah；LSTM 0.2221 Ah**。重复使用相同六个电芯，不应解释为 18 个独立电芯。

机制判断 | 为什么零违例不能证明模型更好

running-min 对每一步取迄今最小值，因此直接阻止向上跳变。两类模型经相同处理后违例率均为 0%，不能将此归因于 PINN 独有能力，更不能等同于实际系统安全。

PINN 在种子 123 下误差明显放大，其他种子也未胜过 LSTM。该协议支持对初始化敏感性的负面观察；原因诊断尚未完成，不扩大为所有 PINN 的一般结论。

适用范围与复核入口

留出电芯的已观测容量仍作为输入特征，实验衡量重建/去噪，未检验未来容量或剩余寿命预测。仓库快照至原始 CALCE 归档的完整来源链尚未闭合。

公开产物包含固定协议、36 条汇总、按种子/模型汇总及可重算汇总的脚本；该轻量核验不重新训练，也不包含逐点预测和模型权重。

[固定源码快照](#) · [三种子报告](#) · [汇总与复核脚本](#)

评测工程与个人实践

可运行评测工具 · 正式 NFCorpus 流程 · Docker 审计

LLM Evaluation Playbook | 三个可执行检查工具

任务包检查：检查必需文件、引用和结构；公开合成样例区分受测者与评审者材料。

Rubric 检查：提示模糊、混合多个要求的评分项。

数值容差检查：执行绝对、相对、百分点、区间和集合等既定规则。

[固定 v0.2.0 Release](#) 有 17 项测试，CI 覆盖 Python 3.9/3.11/3.12。检查器不能替代研究者决定指标或容差是否合理。

个人实践 | 正式数据流程与容器运行

在固定 WSL 工作区完成版本核验、六次合成任务调用与六题方法初稿；随后重建 NFCorpus 数据及 BM25/TF-IDF 排名缓存，3,633 篇文档及三组缓存哈希均与固定基线一致。

验证越界权重在预算计数前被拒绝；六次合法调用均成功，调用前登记假设。按开发集最高 nDCG@10 冻结第 2 轮 k=60、w=0.85，并对 323 条公开测试查询评测一次，指数增益 nDCG@10 为 **0.308123**。 [本次流程摘要](#)

完成 Docker 联通检查、审计镜像构建与运行，归档轨迹核验与合成任务演示通过。本人核对命令与选参逻辑，结合 AI 工具完成操作与记录整理，留存原始日志和复核产物。

轮次	k	BM25 权重	开发 nDCG@10
1	60	0.50	0.265104
2 (选中)	60	0.85	0.267206
3	60	0.95	0.266631
4	100	0.85	0.266165
5	60	0.90	0.266471
6	60	0.80	0.264490

结果解释与申请说明

0.85 是本次六候选中最好，未定位全局峰值；公开测试此前已被探索，本次是流程验证，不作为新盲测或代理胜过搜索的证据。本人为大三学生，预计 2028 年 6 月毕业，申请按成果酌情考虑，愿结合方法、源码与现场运行说明个人掌握情况。

[GitHub 主页](#) · [项目证据页](#) · [研究代理](#) · [LoRA](#) · [电池研究](#)